



RNA-Dee: 基于预训练模型与深度残差网络的RNA二级结构预测平台

数据集构建、模型原理与模型评估方法深度解析

碱基互补配队：蒋贤迪

项目概述：从序列到结构，解码RNA的语言

挑战


- RNA二级结构预测对于理解其生物学功能至关重要，但这是一个高维度、高度稀疏的预测难题。

我们的方法

- 提出RNA-Dee模型，采用“冻结骨干+下游微调”策略，结合预训练语言模型(RNA-FM)的强大表征能力与深度卷积网络(ResNet)的结构解析能力。

本报告焦点

- 本次报告将聚焦于项目实现的核心技术细节：数据集处理流程、模型评估体系的构建理由，以及关键模块的代码实现。



数据管道：构建高质量、可复现的训练基石

数据源


训练/验证数据源

RNAstrAlign, 涵盖tRNA, 5S
rRNA, 16S rRNA 等多个RNA家族。


基准测试数据源

Archivel1, 作为完全独立的测试集，用于评估最终的泛化能力，包含训练集中未出现的RNA种类(如23sRNA)。


预处理流程



演示视频



评估策略：为何F1分数十分重要？



我们选择的指标

精确率 (Precision)：预测为“配对”的样本中有多少是正确的？

Formula: $TP / (TP + FP)$

召回率 (Recall)：所有真实的“配对”样本有多少被成功找出？

Formula: $TP / (TP + FN)$


F1 Score：精确率与召回率的调和平均数，能综合反映模型在不平衡数据上的表现。

Formula: $(2 * Precision * Recall) / (Precision + Recall)$

构建理由 (The Rationale):

在此任务中，F1 分数要求模型在“查准”和“查全”之间取得精妙平衡，是衡量稀疏配对预测任务综合性能最关键、最可靠的指标。

模型架构总览：三大核心模块协同工作



1. 序列特征嵌入 (Embedding):

利用预训练的RNA-FM, 将一维RNA序列 转化为富含进化语义信息的高维向量 ($L \times D$)。

2. 成对特征构建 (Pairwise Construction):

通过创新的“外部拼接” (Outer Concatenation) 操作, 将一维序列特征 “升维” 至二维配对特征图 ($L \times L \times 2D$)。

3. 深度解码与预测 (Deep Decoding):

采用深度残差网络 (ResNet) 从二维特征图中提取长距离依赖关系, 并输出最终的配对概率矩阵 ($L \times L$)。

核心代码(1): 利用RNA-FM 捕捉序列的进化语义

核心理念:

摒弃传统One-hot 编码, 采用预训练的RNA-FM 作为静态、高质量的特征提取器。我们“冻结”其参数, 不进行微调, 以利用其强大知识并降低训练成本。

设计理由:

文献表明, 深层(如第12层)的表征蕴含了更丰富的结构信息。冻结骨干可以有效利用大模型的知识, 同时显著降低下游任务的训练成本和过拟合风险。

#加载预训练的 RNA-FM 模型

```
self.backbone, self.alphabet = fm.pretrained.rna_fm_t12(  
    model_location=rna_fm_model_path  
)
```

#冻结骨干网络, 不计算梯度, 确保稳定性与效率

with torch.no_grad():

#提取第12层Transformer 的隐藏状态作为特征

```
results = self.backbone(tokens, repr_layers=[12])
```


```
embedding = results["representations"][12]
```

#Shape:[B,L,640]

核心代码(2)：“外部拼接”-构建从序列到配对的维度桥梁

核心理念：

如何从 $[L, D]$ 的序列特征得到 $[L, L, 2D]$ 的配对特征？
我们通过PyTorch的广播 (Broadcasting) 机制，巧妙地为每个 (i, j) 位置组合了第 i 个和第 j 个碱基的特征。



```
# 输入 x 形状: [B, L, D]
# 1. 扩展维度并复制, 构建"行"特征
# x.unsqueeze(2) -> [B, L, 1, D]
# .expand -> [B, L, L, D]

x_row = x.unsqueeze(2).expand(-1, -1, L, -1)

# 2. 扩展维度并复制, 构建"列"特征
# x.unsqueeze(1) -> [B, 1, L, D]
# .expand -> [B, L, L, D]

x_col = x.unsqueeze(1).expand(-1, L, -1, -1)

# 3. 在最后一个维度(特征维)进行拼接
# 最终形状: [B, L, L, 2D]

out = torch.cat((x_row, x_col), dim=-1)
```


核心代码(3): ResNet 解码器-从特征图到预测概率

核心理念：

这是模型的决策核心，通过三步完成预测：
降维、深度特征提取、输出。

设计理由：

使用线性层先行降维是控制模型参数和计算量的关键 技巧。16层的ResNet提供了足够的深度来捕捉复杂的 非局部相互作用。



1. 降维层：将 1280 维的高维特征压缩为 128 维

```
self.linear_in = nn.Linear(2 * in_dim, hidden_dim)
```

2. 特征提取器：堆叠 16 层残差网络

```
self.resnet = ResNet2D(hidden_dim, num_blocks, kernel_size)
```

3. 输出层：将特征通道压缩为 1，输出配对得分

```
self.conv_out = nn.Conv2d(hidden_dim, 1, kernel_size=kernel_size,  
padding='same')
```

前向传播流程

```
x = self.outer_concat(x) # 维度变换
```

```
x = self.linear_in(x) # 线性降维
```

```
x = x.permute(0, 3, 1, 2) # 调整维度顺序以适配卷积
```

```
x = self.resnet(x) # 深度残差提取
```

```
x = self.conv_out(x) # 输出最终预测
```

训练过程分析：模型收敛性与超参数选择

关键超参数

优化器 (Optimizer): **AdamW**


学习率 (Learning Rate): **1e-4**

批大小 (Batch Size): **2**

损失函数 (Loss): 二元交叉熵损失函数


正样本权重 (pos_weight) = **10** → 关键: 应对正负样本极度不平衡

训练轮数 (Epochs): **10**



分析：训练损失和验证损失在初期均快速下降，表明模型在有效学习。后期验证损失略有抬头（Epoch 8之后），提示可能存在轻微过拟合，但整体收敛趋势良好，模型并未崩溃。

验证集表现：F1 分数稳步提升



分析：

- 核心指标F1 Score随训练轮数稳步上升，在第10个epoch达到峰值，证明模型的综合性能持续优化。
- 模型在维持高Recall（召回率）的基础上，Precision（精确率）也在逐步提高，说明模型不仅能“找全”真实配对，还能更精准地“找准”，减少误报。

最终基准测试：在ArchiveII 独立测试集上的泛化能力


最终性能评估结果

数据集	准确率	精确率	召回率	F1	AUC
ArchiveII	0.9978	0.7148	0.7432	0.7287	0.9632

关键解读：

- F1 Score: 0.7287**（核心性能指标，表现稳健）。
- Accuracy: 0.9978**（如预期般虚高，反映了对海量负样本的排除能力）。
- AUC: 0.9632**（极高，表明模型的预测概率区分度非常强）。

ROC Curve



分析：

ROC曲线远超对角线，逼近左上角，直观展示了模型在所有分类阈值下都具有出色的分类能力。高达0.9632的AUC值进一步证实了模型的强大判别力。

应用展示： 将模型封装为交互式平台RNA-Dee

实现了用户友好的前端界面，支持四种核心功能：



1. **单序列预测：** 输入FASTA 序列，可
可视化预测二级结构图。




2. **批量文件处理：** 上传多个FASTA 文
件，批量预测并打包下载结果。



3. **验证对比：** 上传带真实结构的. bpseq
文件，与模型预测进行并排对比。



4. **问答助手：** 运用RAG技术，并调用
Qwen的API，让其接受核心代码文件，回
答用户的问题



经验与反思

可重复性

初期未使用固定种子划分数据集导致验证困难，之后又花了大量时间重新训练，让实验结果可被复现。

显存不足

在有限算力(显存)下，需精细调整超参数(如 `batch size`, ResNet 层数)以平衡性能与开销，并明智地选择性计算评估指标。

版本的不同

真实开发中会遇到环境配置、依赖版本冲突(如 `Gradio` 更新)、数据迁移等诸多问题，解决问题的能力与算法设计同等重要。

总结与展望

成功构建:

我成功设计并实现了一个端到端的RNA二级结构预测模型RNA-Dee, 它高效结合了预训练模型RNA-FM的语义理解能力和Resnet的空间特征提取能力。

功能拓展:

我希望后面有时间的话可以修改可视化的参数, 在“验证对比”环节能够增加“红绿球”模式。如果预测正确则为绿球, 如果预测错误则为红球

代码开源:

我希望能能在寒假有时间时, 将我的源代码在Github上开源, 并且在Hugging Face上发布我的模型, 以供其他人使用



感谢聆听

&

Q&A