

背景

图像生成

- 无条件生成：将无意义的**随机噪声**转成清晰图像
- 条件生成：根据 **条件** 引导，生成特定图像

图像矩阵表示

在计算机底层中，图像表示为H (高度)× W (宽度) × C (通道数) 的张量矩阵

噪声与结构化图像

如果不能捕捉到图像中各像素的组合规律（例如完全从随机分布中取值），最终得到的图像只能是没有意义的噪声图像。

因此，要生成有意义的图像，必须学习图像中各像素间的复杂关系

存在一个**真实图像在高维空间中客观存在的概率分布** p_{data} ，如果能够学习到这个分布，在图像生成时让每一个像素都从中采样，就能让生成图像与现实中的图像具备相似的结构特征（如边缘、纹理和语义）

图像分布的近似

但图像分布的**形式未知**，**维度高且结构复杂**，往往不可直接求解

但可以训练一个神经网络模型 p_{θ} 去拟合 p_{data} 。模型根据大量图像优化参数，贴近复杂的图像分布



随着训练进行，模型分布 p_{θ} 与图像分布 p_{data} 会越来越接近，图像也会越来越真实

现如今，一共有四种常见的生成式模型架构

变分自编码器（Variational Autoencoder, VAE）

图像生成难点

图像分布在高维空间分布稀疏，只能通过降维来解决，即高维的像素空间映射到低维的特征空间。不仅可以简化运算，还可以捕捉到数据中最本质、关键的结构信息

模型架构

自编码器是基于降维的无监督学习模型，通过神经网络实现图像的压缩和重构。核心思想是用低维特征向量表示原本的高维图像样本，再从潜空间中重构出接近原始图像的输出。

- Encoder
 - 多层神经网络
 - 下采样
 - 大图变成小向量
 - 空间尺寸被压缩
 - 通道数增加
 - 实现 图像数据 -> 潜空间低维特征 映射
- Decoder
 - 多层神经网络
 - 上采样
 - 小向量恢复成大图
 - 空间尺寸放大
 - 通道数减少
 - 实现 潜空间低维特征 -> 图像数据 的重建
- Code Layer
 - 最后输出隐空间向量的那层，也叫 latent layer
 - 记录图像中的关键特征


训练流程

- 目标：让Decoder重构的图像与原图相似
- 方法：通过降低 重建损失 + KL散度，让模型学会打包和解包图像信息，并学会生成图像
 - **重建损失**
 - 衡量解码后的图片和原始图片相似度,
 - $Loss = (output_{pixel} - input_{pixel})^2$
 - **KL散度**
 - 衡量两个概率分布之间的差距
 - 能够**限制概率分布不退化为点**，中间采样也能有合理的图像，也是与AE的区别
- 图像生成
 - 对于Encoder编码的隐空间向量，Decoder可以重建出对应的图像
 - 不过，对于一个从未在训练过程中出现的隐变量z，Decoder能生成对应含义的图像吗？

样本级对应与分布级对应

- Decoder遇到新z时，往往生成无意义噪声图像

- Decoder只记住z与图像关系，无泛化性
- 训练图像在隐空间中被映射成孤立、不连续的离散点，点与点之间缺乏过渡
- 破局方法：样本级对应 -> 分布级对应
 - 样本级对应
 - 一个点对应一张图像
 - 稍微偏移图像就崩溃
 - 分布级对应
 - 一个分步对应一类相似图像
 - 稍微偏移图像只会微小改变
- VAE的核心思想
 - 不让Encoder输出固定向量，而是输出一个概率分布
 - 将图像分布 p_{data} 映射到一个高斯分布，因此Encoder编码得到的是均值与方差



扩散模型（Diffusion Model）

概述

- 前向过程：图像加噪得到噪声，趋近高斯分布
- 反向过程：多步去噪，还原图像信息，生成图像

去噪模型设计

- 流程：根据t步图像 x_t 与时间 t ，经去噪模型 $f_\theta(x_t, t)$ 后得到 $t - 1$ 步图像 x_{t-1}
- 思路：先预测噪声后再去除，因为噪声遵从高斯分布，学习难度低



去噪模型训练

为了在去噪时预测两步的噪声，模型需要在训练时学习两步之间的噪声

- 想法1：加噪过程中，**按顺序**加入每步噪声时，模型同时学习预测噪声
 - 无法打乱样本数据
- 想法2：采用随机时间步训练，打乱顺序
 - 得加噪t次才能得到训练数据—— x_{t-1} 和 x_t
- 最终想法：单步加噪得到训练数据 x_t
 - 递归加噪过程
 - $q(x_t|x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t}x_{t-1}, \beta_t\mathbf{I})$
 - β_t 为噪声强度

- 单步加噪得到训练数据 x_t
 - $x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon, \quad \epsilon \sim \mathcal{N}(0, \mathbf{I})$
 - $\bar{\alpha}_t = \prod_{i=1}^t \alpha_i, \quad \alpha_t = 1 - \beta_t$
- 去噪过程
 - $p_\theta(x_{t-1}|x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t))$
- 损失函数
 - $L = \mathbb{E}_{t, x_0, \epsilon} [\|\epsilon - \epsilon_\theta(x_t, t)\|^2]$
- 训练流程：
 - 随机采样图像 x_0 , 噪声 ϵ 和时间 t
 - 单步加噪得到噪声图 x_t
 - 学习预测 x_0 与 x_t 之间的总噪声

 alt text

去噪模型推理

1. 给定 t 和 x_t , 预测噪声并减去
2. DDPM里：给去噪结果加上随机采样噪声，生成 x_{t-1} ，以增加多样性

数学公式太多了，手打太麻烦了，还是平板整理好

条件生成

- 问题：无法生成可控图像
- 方法：文本作为模型输入，与图像进行交叉注意力

隐空间扩散

- 问题：生成速度慢（本质是计算量大）
- 方法：使用VAE，在隐空间中扩散

流匹配模型（Flow Matching, FM）

刻画映射的其他方法

扩散模型映射路径

- 逐步加入噪声，得到映射路径
- 由于加噪过程的噪声是随机取样的，所以映射路径是弯曲、随机的

 alt text

新思路：

- 将映射途经拆成若干线段之和
- 计算：已知样本速度，计算每条线段，累加得到总路径

流匹配模型原理

向量场

- 已知状态和时间，样本在此时此处的速度向量，包括速度大小和方向
- 同一 t 下，每个坐标点预设一个速度向量，如 $x_{0.5}$ 对应速度向量为 $v_{0.5}$

原理

- 从随机噪声，通过多步直线路径，生成图像
- 与扩散模型类似，但不同状态的媒介不再是噪声，而是直线路径
- 对于当前步的状态和时间，预测向量场，得到路径和下一步状态

 alt text

流匹配训练过程

- 随机采样噪声 x_0 和样本 x_1
- 通过 $x_t = (1 - t)x_0 + tx_1$ 得到 t 时刻的理想状态
- 根据 x_t 和 t ，预测此时的速度 v_{pred}
- 计算 v_{pred} 与真实 $v = x_1 - x_0$ 之间的 L2 损失

 alt text

与扩散模型对比总结

- 扩散模型
 - 生成图片：多步去除噪声
 - $x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon, \quad \epsilon \sim \mathcal{N}(0, \mathbf{I})$
- 流匹配
 - 生成图片：多步位移
 - $x_t = (1 - t)x_0 + tx_1$